

Dataset yang digunakan dalam penelitian ini terdiri dari 2111 entri data dan 17 atribut, yang berisi informasi mengenai kebiasaan makan, gaya hidup, dan kondisi fisik individu dari tiga negara, yaitu Meksiko, Peru, dan Kolombia. Tujuan utama dari penggunaan dataset ini adalah untuk memperkirakan tingkat obesitas seseorang berdasarkan berbagai fitur yang telah dikumpulkan. Variabel target dalam dataset ini adalah NObesidad yang merepresentasikan kategori tingkat obesitas dan terbagi ke dalam tujuh kelas, yaitu Insufficient Weight, Normal Weight, Overweight Level I, Overweight Level II, Obesity Type I, Obesity Type II, dan Obesity Type III. Data dalam dataset ini berasal dari dua sumber, yaitu sekitar 77% dihasilkan secara sintetis menggunakan metode SMOTE (Synthetic Minority Over-sampling Technique) melalui perangkat lunak Weka, sementara sisanya sebanyak 23% diperoleh secara langsung melalui pengguna yang mengisi data melalui platform web.

Proses eksplorasi data (Exploratory Data Analysis/EDA) menunjukkan bahwa beberapa kolom numerik pada awalnya memiliki tipe data berupa objek (object) dan telah berhasil dikonversi ke dalam bentuk numerik yang sesuai. Selain itu, ditemukan adanya missing values pada beberapa kolom yang kemudian ditangani dalam tahap preprocessing. Distribusi data pada variabel target juga tidak seimbang secara sempurna, yang menjadi perhatian dalam pengolahan data selanjutnya. Namun, tidak ditemukan duplikasi data yang signifikan dalam dataset. Beberapa outlier terdeteksi, khususnya pada kolom Weight, Height, dan Age, yang kemudian diatasi melalui pendekatan penanganan outlier pada tahap pembersihan data.

Dalam proses preprocessing, data telah dibersihkan dari nilai duplikat, missing values, dan outlier sehingga dataset menjadi lebih siap untuk dianalisis lebih lanjut. Semua fitur kategorikal telah dikonversi menjadi bentuk numerik, baik melalui label encoding maupun teknik lainnya yang sesuai. Ketidakseimbangan pada kelas target diatasi dengan pendekatan SMOTE untuk menghasilkan distribusi kelas yang lebih proporsional. Fitur numerik dalam dataset juga telah dinormalisasi menggunakan metode StandardScaler agar memiliki skala yang seragam dan tidak bias terhadap model pembelajaran mesin yang sensitif terhadap skala data. Dengan demikian, dataset telah memenuhi syarat untuk digunakan dalam proses modeling machine learning.

Beberapa algoritma klasifikasi telah diterapkan untuk memodelkan data ini, yaitu Random Forest, Decision Tree, dan K-Nearest Neighbors (KNN). Dari ketiga model tersebut, Random Forest menunjukkan performa terbaik dengan akurasi dan nilai F1-score tertinggi, menjadikannya model yang paling direkomendasikan untuk klasifikasi tingkat obesitas. Meskipun Decision Tree memiliki keunggulan dalam kecepatan pelatihan, performanya masih berada di bawah Random Forest. Di sisi lain, model KNN cenderung lebih lambat dan kurang stabil, terutama ketika jumlah fitur dan ukuran dataset meningkat. Hal ini disebabkan oleh sifat KNN yang sensitif terhadap skala dan dimensi data, serta ketergantungannya pada perhitungan jarak yang kompleks.

Selanjutnya, dilakukan proses tuning hyperparameter pada ketiga model utama—Random Forest, Logistic Regression, dan KNN—dengan menggunakan metode GridSearchCV dan 5-fold cross-validation untuk menemukan konfigurasi parameter terbaik yang dapat

meningkatkan performa model. Hasil tuning menunjukkan bahwa Random Forest memiliki kombinasi parameter terbaik pada nilai `n_estimators=200`, `max_depth=None`, `min_samples_split=2`, dan `min_samples_leaf=1`. Meskipun demikian, performa model sedikit menurun pada data uji, yang kemungkinan disebabkan oleh gejala overfitting akibat terlalu cocok dengan data pelatihan. Sementara itu, Logistic Regression dan KNN menunjukkan adanya peningkatan performa setelah proses tuning, yang mengindikasikan bahwa kedua model ini lebih sensitif terhadap penyesuaian parameter dan cenderung mampu menggeneralisasi data uji dengan lebih baik.

Berdasarkan seluruh rangkaian analisis tersebut, dapat disimpulkan bahwa Random Forest tetap menjadi pilihan model terbaik untuk klasifikasi obesitas karena konsistensinya dalam menghasilkan performa yang tinggi, baik sebelum maupun sesudah tuning. Namun, perhatian perlu diberikan terhadap potensi overfitting, terutama saat digunakan dengan parameter yang sangat kompleks. Logistic Regression dapat dijadikan alternatif jika diperlukan model yang lebih sederhana dan mudah diinterpretasikan. Dengan persiapan data yang matang dan pemilihan model yang sesuai, sistem klasifikasi tingkat obesitas ini dapat berfungsi secara optimal dalam memberikan prediksi yang akurat berdasarkan atribut gaya hidup dan kondisi fisik responden.